


让复杂 AI 工作可治理，而不是假装可靠

一个 Codex Skill：用红队、蓝队、裁判、验证和审计，把复杂生成任务变成可追踪的治理闭环。



一轮闭环，多个角色，证据可见

MAGG 不是堆角色，而是让每个角色的职责、输入、输出和验证边界都留下痕迹。



没有 session 证据，就不能叫真实线程

同一会话内的角色扮演可以有用，但不能宣称为独立多线程审查。

红队-1

session id

项目路径

最小输入

独立 outbox

蓝队-1

session id

项目路径

最小输入

独立 outbox

裁判-1

session id

项目路径

最小输入

独立 outbox

验证-1

session id

项目路径

最小输入

独立 outbox

验证分层，让结论诚实

每份验证报告都明确：已验证、失败、未验证、环境缺口、不能宣称。

L0 结构

L1 规则

L2 路径

L3 结果

自优化先定义评测，再修改 Skill

Skill 可以自我进化，但必须有 baseline、通过/失败标准、无泄漏 prompt 和审计记录。

评测契约

范围锁定

裁判允许

源码修改

前向测试

交付的不只是文件，而是可追溯过程

这个仓库包含 MAGG Skill、README 可视化流程图，以及用于展示的 PDF/PTX。

主说明

参考

模板

案例

视觉版

Govern complex AI work without pretending

A Codex Skill for red/blue/judge governance, evidence, controlled writes, and validation.



One loop, separate jobs, visible evidence

MAGG records responsibility, input, output, and validation boundaries.



No session evidence, no true thread

Same-session roleplay may help, but it cannot be claimed as independent review.

Red-1

session id
project path
minimal input
own outbox

Blue-1

session id
project path
minimal input
own outbox

Judge-1

session id
project path
minimal input
own outbox

Val-1

session id
project path
minimal input
own outbox

Validation levels keep claims honest

Every report separates verified, failed, not verified, environment gaps, and cannot claim.

L0 Static


L1 Rules

L2 Use

L3 Outcome

Self-optimization starts with evals

A skill can improve itself, but it needs a baseline, pass/fail criteria, no-leak prompts, and an audit trail.



Ship artifacts with an audit trail

This repository packages the MAGG Skill, visual README diagrams, and a shareable PDF/PPTX storyboard.

SKILL.md

references

templates

examples

deck